



Facultad
de
Ciencias

PROYECTO DE MINERÍA DE DATOS

Realizado por

- Martínez Hidalgo Paola Mildred - 319300217
- Trujillo Beltrán Zianya Nenetzi - 319210787
- Toporek Coca Eric - 314284987
- Cruz Campos José Eduardo - 319312087

TABLA DE CONTENIDO

- Propuesta de problemática y justificación **01**
- Preprocesamiento del dataset **02**
- Análisis Exploratorio de Datos **03**
- Modelo Supervisado **04**
- Agrupamiento (Clustering) **05**

PROBLEMÁTICA

Problema: México presenta altos números de personas con diabetes, hipertension, etc, factores que complican enfermedades respiratorias y los métodos actuales no detectan con precisión el riesgo de pacientes con múltiples comorbilidades provocando hospitalizaciones innecesarias o tratamientos tardíos.

Solución: Aplicamos minería de datos sobre registros históricos de salud para identificar patrones ocultos y predecir el riesgo de mortalidad.

Beneficio esperado: Mejor atención médica, optimización de recursos hospitalarios y apoyo a la toma de decisiones en salud pública.



PREPROCESAMIENTO

Objetivo

Preparar el dataset de la DGE para garantizar calidad, consistencia y compatibilidad con los modelos de minería de datos.

Dataset utilizado

- 222K registros
- 42 variables
- Periodo: Enero2025-Mayo2026
- Datos de COVID-19, Influenza y enfermedades respiratorias.

Problemáticas

- No había valores NaN reales, estaban codificados 97/98/99
- No había una variable con el edo. clínico.
- Encoding inconsistente del catálogo (1/2 en lugar de 1/0)

El dataset lo descargados desde la página de datosabiertos en Salud pública:

https://datosabiertos.salud.gob.mx/gobmx/salud/datos_abiertos/datos_abiertos_influenza_covid19.zip

PLAN DE ACCIÓN



Eliminación de duplicados



Transformación de datos 97/98/99 a NaN



Creación de variable Severidad para el análisis clínico




Consistencia binaria, cambiamos el 1/ 2 a valores binarios 1/0

Hallazgos del

ANÁLISIS EXPLORATORIO DE DATOS


COVID-19 / Influenza en México · DGE 2025–2026



¿QUIÉNES SON LOS PACIENTES?

DISTRIBUCIÓN DE EDAD

Pacientes COVID-19/Influenza en México: histograma de EDAD



Mediana

32 años

Paciente típico – más representativo

Media

35 años


Jalada por adultos mayores

Moda

1 año

14,579 lactantes – grupo más frecuente

VARIANZA Y DESVIACIÓN ESTÁNDAR



Desviación estándar
26.44 años


- Rango típico de edades
- 9 años ($35.10 - 26.44$)
 - 62 años ($35.10 + 26.44$)

Esta amplitud refleja que ambas enfermedades afectan a personas de distintos grupos etarios y no se concentran exclusivamente en una edad específica.

DISTRIBUCIÓN DE SEVERIDAD

Los resultados muestran que la categoría más frecuente fue Leve, con 116,190 pacientes (52.2%), seguida de la categoría Grave, con 93,828 pacientes (42.2%). Los casos Críticos representaron 4,114 pacientes (1.8%), mientras que 8,247 pacientes (3.7%) fueron clasificados como Fallecidos.


Esta distribución indica que poco más de la mitad de los pacientes pesentó cuadros leves; sin embargo, una proporción considerable evolucionó hacia condiciones graves, críticas o fallecimiento.



MATRIZ DE CORRELACIÓN


Relaciones entre comorbilidades:

- Diabetes e hipertensión ($\rho = 0.49$): Esta relación moderada indica que ambas enfermedades tienden a coexistir con frecuencia en los mismos pacientes.
- Edad e hipertensión ($\rho = 0.47$): La prevalencia de esta enfermedad aumenta conforme incrementa la edad de los pacientes.
- Edad y diabetes ($\rho = 0.41$): Indica una mayor presencia de esta comorbilidad en adultos y adultos mayores.
- Edad y EPOC ($\rho = 0.24$): Muestra que esta enfermedad respiratoria crónica es más frecuente en grupos de mayor edad.




DISTRIBUCIÓN DE SEVERIDAD



Los resultados muestran una importante presencia de enfermedades crónicas no transmisibles dentro de la población analizada, particularmente hipertensión y diabetes. Este hallazgo coincide con el perfil epidemiológico de México, donde estas patologías representan algunos de los principales problemas de salud pública.





REGLAS DE ASOCIACIÓN (APRIORI)

- El **76.7%** de los pacientes que presentan simultáneamente **diabetes** y **enfermedad renal crónica** también presentan **hipertensión** y pertenecen al grupo de pacientes **severos**.
 - Aproximadamente el **62.6%** de los pacientes con **enfermedad renal crónica** presentan simultáneamente **hipertensión** y evolucionan hacia cuadros **severos**.
 - Más de la **mitad** de los pacientes que presentan **diabetes** y **obesidad** desarrollan simultáneamente **hipertensión** y pertenecen al grupo **severo**.
 - Los pacientes con **antecedentes cardiovasculares** presentan una alta probabilidad de encontrarse en el grupo **severo** junto con **hipertensión**, reforzando la importancia de las enfermedades cardiovasculares como factores asociados a una evolución clínica desfavorable.
- 



MODELO SUPERVISADO


COVID-19 / Influenza en México · DGE 2025–2026


VARIABLE OBJETIVO

La variable **SEVERIDAD** se divide en cuatro niveles:

- **Nivel 0:** Leve – Ambulatorio
- **Nivel 1:** Grave – Hospitalizado
- **Nivel 2:** Crítico – UCI o Intubado
- **Nivel 3:** Fallecido



Fabricando Modelos





modelo	accuracy	precision_macro	recall_macro	f1_macro	f1_weighted
Decision Tree	0.750090	0.484975	0.546037	0.487459	0.776517
Random Forest	0.803490	0.521147	0.580518	0.536013	0.819380
XGBoost	0.723851	0.512749	0.651000	0.501058	0.763645

Rendimiento



Importancia de Variables





Diagrama de Flujo Clínico Derivado del Árbol de Decisión (max_depth=3)



CLUSTERING

1

Objetivo: identificar perfiles distintivos de pacientes COVID-19 en México. Para ello aplicaremos técnicas de agrupamiento supervisado y no supervisado sobre el dataset previamente preprocesado, buscando generar una comprensión más profunda de los patrones de la enfermedad y resaltar su relevancia clínica y metodológica.



Agrupamiento K-Means



Análisis Jerárquico

Elegimos K-Means como algoritmo principal porque es el más viable para gran cantidad de registros y estructura del dataset (grupos compactos en espacio estandarizado). El jerárquico es la herramienta de validación que le da respaldo al resultado. Es decir, K-Means encuentra los clusters, el jerárquico los confirma.



DATOS UTILIZADOS

- 222 K registros
- Selección de 13 variables divididas en 2 grupos: demográficas (Edad, sexo, embarazo)
- comorbilidades (diabetes, hipertension, asma, etc.)


Se excluyeron TIPO_PACIENTE, UCI, INTUBADO, NEUMONIA y SEVERIDAD porque son resultados médicos, no factores de riesgo previos

Con 13 variables no es posible visualizar los clusters directamente. Por lo que aplicamos PCA para comprimir a 2 dimensiones únicamente con fines de visualización, el clustering se calculó siempre sobre las 13 variables completas.

Análisis de Componentes Principales — COVID-19 México




COEFICIENTE DEL CODO



La inercia cae rápidamente de $k=1$ a $k=4$; a partir de $k=5$ la reducción se vuelve marginal. El punto de inflexión ('codo') se observa en $k=4$, lo que indica que 4 clusters es el número óptimo para este dataset.


COEFICIENTE DE SILUETA



El coeficiente de silueta alcanza su valor máximo en $k=5$, confirmando que con 5 clusters los grupos son más cohesivos internamente y más separados entre sí. Este resultado es consistente con lo que muestra el método del codo.


RESULTADOS K-MEANS

Severidad Real vs. Clusters K-Means — Espacio t-SNE (submuestra 30,000 registros)



K-Means se ejecutó sobre los 222,379 registros con $k=4$. Para visualizar los clusters se usó t-SNE, que agrupa a los pacientes en 2D por similitud de perfil. El panel izquierdo muestra la severidad real; el derecho, lo que encontró el algoritmo sin verla. La correspondencia parcial entre ambos confirma que los clusters capturan patrones de riesgo reales.

CLUSTERING JERARQUICO



El dendrograma agrupa los 80 pacientes en 4 ramas principales. Los pacientes con el mismo nivel de severidad clínica tienden a quedar en la misma rama, lo que valida que las variables de clustering son informativas para distinguir perfiles de riesgo.

EVALUACIÓN DEL AGRUPAMIENTO (MÉTRICAS DE CALIDAD)

Usamos métricas internas (Silueta) para evaluar la calidad de los clusters por sí solos, y métricas externas (ARI, Rand Index) para comparar contra la severidad clínica real.

Métrica	K-Means	Jerárquico
ARI	0.0487	0.0124
Rand Index	0.5372	0.4238
Silueta	0.2659	0.4503

ARI (0.05): los clusters coinciden poco con la severidad real, pero no es aleatorio, el modelo agrupa por perfil de riesgo, no por desenlace.

Rand Index (0.54): 54 de cada 100 pares de pacientes quedaron agrupados igual que en la clasificación médica.

Silueta (0.27): los 4 grupos existen pero sus bordes se solapan, esperado con variables binarias.

CONCLUSIONES CLUSTERING

1. Se identificaron **4 perfiles poblacionales** clínicamente interpretables a partir de solo 13 variables de factores de riesgo, sin ningún resultado médico.

Mujeres Jóvenes sin Riesgo

Porcentaje:	43.2%
Edad media:	29.9 años
Severidad media:	0.41

Hombres Jóvenes sin Riesgo

Porcentaje:	36.6%
Edad media:	25.1 años
Severidad media:	0.57

Adultos Mayores con S. Metabólico

Porcentaje:	18.9%
Edad media:	66.9 años
Severidad media:	0.94

Mujeres Embarazadas

Porcentaje:	1.3%
Edad media:	27.5 años
Severidad media:	0.50

CONCLUSIONES

La aplicación de técnicas de minería de datos permitió identificar patrones, tendencias y perfiles de riesgo dentro de la población analizada. Los resultados muestran que variables como la edad, las comorbilidades y otros factores demográficos contienen información valiosa para comprender la evolución clínica de los pacientes.

Mediante el análisis exploratorio, las reglas de asociación y el clustering fue posible detectar grupos vulnerables y combinaciones de factores de riesgo que se relacionan con cuadros más severos.

Esta información puede utilizarse para apoyar estrategias de prevención, vigilancia epidemiológica y asignación eficiente de recursos de salud.

Asimismo, estos hallazgos constituyen una base para el desarrollo de modelos predictivos capaces de estimar el riesgo de complicaciones o fallecimiento, contribuyendo a una atención médica más temprana y a una mejor toma de decisiones clínicas.

LIMITACIONES

Este trabajo demuestra el potencial de la minería de datos para apoyar la identificación temprana de pacientes vulnerables; sin embargo, la complejidad de las enfermedades respiratorias implica que ningún modelo puede explicar completamente todos los factores involucrados en la evolución clínica de una persona. Aspectos biológicos, ambientales, sociales y de acceso a la atención médica pueden influir en los resultados y no siempre están representados en los datos disponibles.

Asimismo, los modelos contruidos se basan en información histórica, por lo que requieren actualización y validación continua para adaptarse a cambios epidemiológicos, nuevas variantes virales o modificaciones en los protocolos de atención. En consecuencia, estas herramientas deben entenderse como un apoyo para la toma de decisiones y la generación de estrategias preventivas, complementando el conocimiento y la experiencia de los profesionales de la salud.



**GRACIAS POR SU
ATENCIÓN**