



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

ALMACENES Y MINERÍA DE DATOS

2026-2

Proyecto Final

ALUMNOS:

Cruz Campos José Eduardo - 319312087
Martínez Hidalgo Paola Mildred - 319300217
Trujillo Beltrán Zianya Nenetzi - 319210787
Toporek Coca Eric - 314284987

FECHA DE ENTREGA:
10 de junio de 2026

PROFESOR:
Jessica Santizo Galicia

AYUDANTES:
Diego Antonio Villalba González
Ares Gael Castro Romero



Índice

1. Introducción	1
1.1. Antecedentes y Contexto	1
1.2. El Problema Central	1
1.3. Objetivos y Pregunta de Investigación	1
1.4. Justificación y Valor del Proyecto	2
2. Descripción del Dataset	2
2.1. Fuente y Características Generales	2
2.2. Variables Principales	2
2.3. Limitaciones Conocidas de los Datos	3
3. Limpieza y Preparación de Datos	3
3.1. Tratamiento de Códigos Especiales y Valores Faltantes	4
3.2. Construcción de la Variable Objetivo: SEVERIDAD	4
3.3. Transformaciones, Encoding y Escalado	4
4. Análisis Exploratorio de Datos (EDA)	5
4.1. Estadísticas Descriptivas y Target	5
4.2. Prevalencia de Comorbilidades	5
4.3. Análisis de Correlación de Spearman	6
4.4. Reglas de Asociación (Algoritmo Apriori)	7
5. Modelo Supervisado de Clasificación	7
5.1. Definición del Experimento y Evitación de Target Leakage	7
5.2. Justificación de la Métrica Principal: Macro F1-score	8
5.3. Resultados y Comparativa de Rendimiento	8
5.4. Curvas ROC y Feature Importance	9
5.5. Interpretación del Árbol de Decisión como Protocolo Clínico	10
6. Clustering (Agrupamiento)	10
6.1. Metodología y Selección del Número de Clusters	11
6.2. Visualización y Perfilado de los Clusters	11
6.3. Validación de Clusters contra la Severidad Real	12
7. Arquitectura y Diseño del Sistema	13
7.1. Justificación de la Arquitectura y Patrones de Diseño	13
7.2. Diagrama de Clases UML	14
7.3. Arquitectura del Sistema y Flujo de Datos	15
8. Reutilización del Modelo	16
8.1. Proceso de Serialización	16
8.2. Demostración de Carga y Predicción en Frío (Notebook 05)	16
9. Conclusiones y Trabajo Futuro	17

9.1. Hallazgos Principales	17
9.2. Limitaciones del Trabajo	18
9.3. Trabajo Futuro	18
10. Referencias	19

Índice de figuras

1.	Distribución porcentual de la variable objetivo ordinal SEVERIDAD	5
2.	Prevalencia de comorbilidades crónicas y condiciones de riesgo en la muestra analizada	6
3.	Matriz de correlación de Spearman de comorbilidades, datos demográficos y severidad	7
4.	Matrices de confusión de los mejores clasificadores entrenados	9
5.	Curvas ROC One-vs-Rest en conjunto de prueba para el clasificador óptimo	9
6.	Clasificación de importancia de variables para la estimación de la severidad	10
7.	Evaluación de número óptimo de clusters para K-Means	11
8.	Dendrograma del agrupamiento jerárquico (Muestra de 5,000 casos)	11
9.	Heatmap de perfiles medios por variable clínica para los 4 clusters de K-Means	12
10.	Tabla de contingencia que muestra el porcentaje de severidad real por cluster	13
11.	Diagrama de Clases UML detallado de la arquitectura del sistema	15
12.	Diagrama de flujo operativo y arquitectura de datos del sistema	16

Índice de tablas

1.	Variables principales del dataset de la DGE	3
2.	Métricas comparativas en el conjunto de prueba para el triage clínico	8
3.	Resumen y perfiles promedio de los 4 clusters de K-Means	12
4.	Comparación métrica de calidad entre K-Means y Agrupamiento Jerárquico	13

1 Introducción

1.1 Antecedentes y Contexto

El sistema de salud pública en México enfrenta una crisis estructural crónica debido a la transición epidemiológica de su población, caracterizada por una alarmante prevalencia de enfermedades crónico-degenerativas. De acuerdo con datos oficiales, México ocupa los primeros lugares a nivel mundial en obesidad, diabetes mellitus e hipertensión arterial. Esta base de vulnerabilidad metabólica se transforma en un factor crítico cuando la población interactúa con patologías respiratorias agudas (como influenza, virus sincitial respiratorio y SARS-CoV-2), las cuales se presentan de manera estacional o pandémica.

1.2 El Problema Central

El núcleo del problema radica en la **dificultad para estratificar de manera oportuna y predictiva el riesgo de complicación clínica (hospitalización, intubación o deceso) de un paciente al momento de ingresar a los servicios de salud.**

Actualmente, los protocolos de *triage* hospitalario se basan en sintomatología inmediata y criterios lineales que, si bien son útiles, subestiman el efecto sinérgico e interactivo de las comorbilidades múltiples (multimorbilidad). Una combinación específica de factores (por ejemplo, un rango de edad intermedio sumado a tabaquismo crónico y obesidad grado I) puede presentar un riesgo de letalidad equivalente o superior al de un adulto mayor sano, pero pasa desapercibida bajo los esquemas de evaluación tradicionales.

Esta falta de herramientas analíticas avanzadas provoca dos fenómenos perjudiciales para la salud pública:

1. **Saturación innecesaria de unidades médicas:** Hospitalización preventiva de pacientes de bajo riesgo real, consumiendo insumos críticos.
2. **Altas tasas de mortalidad prevenible:** Alta hospitalaria o retraso en la atención de pacientes cuya aparente estabilidad inicial enmascara un riesgo inminente de deterioro sistémico.

El sistema de salud genera millones de registros clínicos a través de la Dirección General de Epidemiología (DGE); sin embargo, este volumen masivo de información permanece subutilizado, tratándose como un repositorio meramente estadístico e histórico, en lugar de explotarse como un activo estratégico en tiempo real para el soporte clínico.

1.3 Objetivos y Pregunta de Investigación

Este proyecto busca responder a la siguiente interrogante:

¿Cómo pueden las técnicas de minería de datos (aprendizaje supervisado y no supervisado) aplicadas a los datos históricos de la DGE identificar patrones ocultos de multimorbilidad y clasificar con precisión el riesgo de mortalidad en pacientes mexicanos,

optimizando así la toma de decisiones clínicas?

Los objetivos específicos del trabajo incluyen:

- Diseñar y aplicar un pipeline reproducible de preprocesamiento de datos para los registros históricos de enfermedades respiratorias.
- Realizar un análisis exploratorio avanzado (EDA) que revele la prevalencia de comorbilidades y descubra reglas de asociación sobre el perfil de riesgo del paciente mexicano.
- Desarrollar y evaluar comparativamente tres modelos de clasificación supervisada para estimar la severidad del paciente desde el triage de ingreso.
- Implementar técnicas de agrupamiento (clustering) no supervisado para caracterizar perfiles de riesgo y contrastarlos con la severidad clínica real.
- Validar la arquitectura del sistema mediante patrones de diseño orientados a la reutilización y modularidad.

1.4 Justificación y Valor del Proyecto

La presente investigación se justifica por su impacto directo en la asignación justa y eficiente de recursos médicos escasos (como camas de terapia intensiva y ventiladores mecánicos). Aportar un modelo matemático interpretable permite a los médicos de primer contacto tomar decisiones basadas en datos reales de la población mexicana y no en modelos importados de países con realidades demográficas y genéticas radicalmente distintas.

2 Descripción del Dataset

2.1 Fuente y Características Generales

El conjunto de datos utilizado proviene del sistema de datos abiertos de la **Dirección General de Epidemiología (DGE)** de la Secretaría de Salud de México. Corresponde al sistema de vigilancia centinela para enfermedades respiratorias virales. El conjunto de datos limpio final consta de **222,379 registros** individuales anonimizados y **42 variables originales** (expandidas a 44 tras el procesamiento), lo que representa una muestra de alta fidelidad poblacional de las olas epidémicas de 2025 y 2026.

2.2 Variables Principales

Las variables que conforman el estudio se agrupan en cuatro categorías fundamentales, descritas en la Tabla 1.

Tabla 1: Variables principales del dataset de la DGE

Categoría	Variable	Descripción y Codificación
Demográficas	EDAD	Edad del paciente en años cumplidos (continua).
	SEXO	Sexo biológico (codificado en binario 0 = Mujer, 1 = Hombre).
	EMBARAZO	Estado de gestación (1 = Sí, 0 = No / No aplica).
Comorbilidades	DIABETES	Presencia de Diabetes Mellitus (1 = Sí, 0 = No).
	HIPERTENSION	Presencia de Hipertensión Arterial (1 = Sí, 0 = No).
	OBESIDAD	Presencia de Obesidad clínica (1 = Sí, 0 = No).
	EPOC	Enfermedad Pulmonar Obstructiva Crónica (1 = Sí, 0 = No).
	RENAL_CRONICA	Insuficiencia renal crónica (1 = Sí, 0 = No).
Clínicas iniciales	TABAQUISMO	Antecedente de tabaquismo activo (1 = Sí, 0 = No).
	NEUMONIA	Diagnóstico clínico de neumonía al ingreso (1 = Sí, 0 = No).
	SECTOR	Sector del sistema de salud que atiende (IMSS, ISSSTE, SSA, etc.).
Desenlace	TIPO_PACIENTE	Modalidad de atención (0 = Ambulatorio, 1 = Hospitalizado).
(Derivadas)	UCI	Ingreso a Unidad de Cuidados Intensivos (1 = Sí, 0 = No).
	INTUBADO	Requerimiento de ventilación mecánica asistida (1 = Sí, 0 = No).
	FECHA_DEF	Fecha de defunción (usada para marcar la mortalidad).

2.3 Limitaciones Conocidas de los Datos

A pesar de su volumen y representatividad, el dataset presenta limitaciones intrínsecas:

- **Subregistro y retraso de notificación:** Depende del llenado de los formatos de estudio epidemiológico en las clínicas de salud, lo que puede inducir a omisiones voluntarias o involuntarias de antecedentes médicos.
- **Códigos especiales no reales:** La base original utiliza códigos numéricos centinela (97, 98, 99) para representar condiciones no aplicables, valores ignorados o no especificados, lo que imposibilita un análisis cuantitativo directo si no se preprocesan adecuadamente.
- **Falta de variables de tratamiento:** No cuenta con detalles sobre fármacos administrados, disponibilidad hospitalaria al momento del triage o tiempos detallados de atención clínica.

3 Limpieza y Preparación de Datos

El pipeline de preprocesamiento de datos se estructuró de manera reproducible e incluyó decisiones críticas justificadas metodológicamente:

3.1 Tratamiento de Códigos Especiales y Valores Faltantes

En las variables clínicas, comorbilidades y demográficas binarias, la base original codifica los nulos como 97 (No aplica), 98 (Se ignora) y 99 (No especificado).

- **Decisión:** Se reemplazaron estos códigos por NaN en las columnas clínicas de comorbilidades y demográficas binarias.
- **Justificación:** Eliminar los registros con valores faltantes reduciría la muestra severamente y sesgaría los modelos eliminando pacientes con historiales incompletos. Dado que los algoritmos basados en árboles (Random Forest, XGBoost) manejan valores NaN de forma nativa durante su entrenamiento y predicción, esta estrategia maximiza la retención de datos.
- **Manejo de defunciones:** El valor centinela 9999-99-99 en la columna FECHA_DEF (que representa la supervivencia del paciente) se convirtió a un tipo de dato de fecha no disponible (NaT). Esto permite operar algebraicamente la columna de fecha e identificar sobrevivientes de forma limpia mediante `isna()`.

3.2 Construcción de la Variable Objetivo: SEVERIDAD

Dado que el dataset no posee una variable única de severidad del cuadro clínico, se construyó la variable objetivo ordinal **SEVERIDAD** con cuatro niveles exclusivos mediante una lógica de prioridad descendente:

1. **Clase 0: Leve** → Paciente tratado de forma ambulatoria (`TIPO_PACIENTE = 1` original).
2. **Clase 1: Grave** → Paciente que requirió hospitalización (`TIPO_PACIENTE = 2` original) pero no ingresó a terapia intensiva (`UCI`) ni requirió intubación.
3. **Clase 2: Crítico** → Paciente hospitalizado que requirió ingreso a la Unidad de Cuidados Intensivos (`UCI = 1`) o ventilación mecánica asistida (`INTUBADO = 1`).
4. **Clase 3: Fallecido** → Todo paciente que presente una fecha de defunción válida registrada (`FECHA_DEF` no nula).

3.3 Transformaciones, Encoding y Escalado

- **Encoding Binario:** Las variables categóricas representadas originalmente como 1 (Sí) y 2 (No) se transformaron a la escala binaria estándar $[0, 1]$, donde 1 representa la presencia/condición positiva y 0 la ausencia. Lo mismo se aplicó para `TIPO_PACIENTE` y `SEXO`.
- **Escalado de Numéricas:** La variable continua `EDAD` se estandarizó mediante el ajuste de un estimador `StandardScaler`, dando origen a `EDAD_SCALED` con media $\mu \approx 0$ y desviación estándar $\sigma \approx 1$. La variable original `EDAD` se mantuvo para fines de visualización y análisis exploratorio interpretable en años reales.

El resultado final del preprocesamiento arrojó un dataset consolidado de **222,379 filas y 44 columnas** guardado en el archivo estructurado `data/COVID19MEXICO_clean.csv`.

4 Análisis Exploratorio de Datos (EDA)

4.1 Estadísticas Descriptivas y Target

El análisis preliminar indica que la población presenta una edad media de **35.1 años** con una desviación estándar sustancial de **26.4 años**, evidenciando un perfil demográfico amplio. La variable objetivo **SEVERIDAD** exhibe un marcado desbalance de clases, lo que describe la pirámide natural de severidad epidemiológica (Figura 1):

- **Leve (Clase 0): 52.2 %**
- **Grave (Clase 1): 42.2 %**
- **Crítico (Clase 2): 1.8 %**
- **Fallecido (Clase 3): 3.7 %**




Figura 1: Distribución porcentual de la variable objetivo ordinal SEVERIDAD

4.2 Prevalencia de Comorbilidades

La frecuencia de enfermedades crónicas en los registros refleja las patologías nacionales dominantes (Figura 2): la **Hipertensión Arterial (15.9 %)** y la **Diabetes Mellitus (13.1 %)** son las comorbilidades con mayor prevalencia en la muestra, seguidas por la **Obesidad (6.6 %)** y el **Tabaquismo (4.3 %)**. Las afecciones cardiovasculares, renales crónicas, inmunosupresión y EPOC se mantienen cerca de una prevalencia del 3 % cada una.




Figura 2: Prevalencia de comorbilidades crónicas y condiciones de riesgo en la muestra analizada

4.3 Análisis de Correlación de Spearman

Se seleccionó el coeficiente de correlación de rangos de Spearman debido a la naturaleza binaria u ordinal de las comorbilidades y del target (Figura 3):

- La variable clínica individual con mayor asociación lineal al target **SEVERIDAD** es la **Neumonía** ($\rho = 0,58$), confirmando que el compromiso pulmonar inicial es el principal detonante clínico del deterioro.
- Entre las comorbilidades crónicas, la Diabetes ($\rho = 0,18$), la Hipertensión ($\rho = 0,18$), la EPOC ($\rho = 0,16$) y la Enfermedad Renal Crónica ($\rho = 0,16$) muestran las asociaciones positivas más notables con la severidad.
- Se identificó una fuerte correlación clínica entre **Diabetes e Hipertensión** ($\rho = 0,49$), sugiriendo una alta tasa de coexistencia (síndrome metabólico) en la población adulta mexicana ingresada.




Figura 3: Matriz de correlación de Spearman de comorbilidades, datos demográficos y severidad

4.4 Reglas de Asociación (Algoritmo Apriori)

Para profundizar en las relaciones de comorbilidad y severidad clínica, se aplicó el algoritmo Apriori, el cual permitió extraer reglas relevantes basadas en métricas de confianza y elevación (lift):

- **Regla 1:** {DIABETES, RENAL_CRONICA} $\Rightarrow$ {HIPERTENSION, SEVERO}
 - **Confianza:** 76.7 % de los pacientes con esta combinación cumplen la regla.
 - **Lift:** 7.18 (ocurre más de siete veces por encima de lo esperado por azar).
- **Regla 2:** {RENAL_CRONICA} $\Rightarrow$ {HIPERTENSION, SEVERO}
 - **Confianza:** 62.6 % de los pacientes presentan simultáneamente esta transición.
 - **Lift:** 5.86.
- **Regla 3:** {DIABETES, OBESIDAD} $\Rightarrow$ {HIPERTENSION, SEVERO}
 - **Confianza:** 53.4 % de confianza y un lift de 5.01, consolidando la peligrosidad de la triada metabólica clásica.

5 Modelo Supervisado de Clasificación

5.1 Definición del Experimento y Evitación de Target Leakage

Se entrenaron tres algoritmos clasificadores de complejidad creciente: **Decision Tree (DT)**, **Random Forest (RF)** y **XGBoost (XGB)**. Para garantizar que el modelo sea de utilidad práctica al

momento del triage clínico de admisión, se excluyeron del conjunto de entrenamiento las variables TIPO_PACIENTE, UCI, INTUBADO y FECHA_DEF. Su inclusión generaría una fuga de información (target leakage) debido a que componen directamente la definición lógica de la severidad, resultando en modelos triviales incapaces de generalizar.

5.2 Justificación de la Métrica Principal: Macro F1-score

El desbalance de las clases objetivo (**SEVERIDAD** = 2 representa solo el 1.8% y **SEVERIDAD** = 3 el 3.7%) hace inviable el uso del *Accuracy* como métrica guía. Un modelo ingenuo que prediga siempre clases mayoritarias obtendría un 94.4% de exactitud global, pero registraría un fallo del 100% al identificar casos críticos y defunciones. Por ello, la métrica de selección de hiperparámetros y optimización adoptada es el ****Macro F1-score****, la cual promedia aritméticamente de manera no ponderada el desempeño del F1 de cada una de las cuatro clases, penalizando severamente los falsos negativos en los grupos minoritarios de alto riesgo.


Para contrarrestar el desbalance durante el entrenamiento, se implementaron pesos de clase inversamente proporcionales a su frecuencia. En los árboles y bosques de Scikit-Learn se configuró `class_weight='balanced'`, mientras que para XGBoost se computó y aplicó un vector dinámico de `sample_weight` en el método `fit()`.

5.3 Resultados y Comparativa de Rendimiento

La Tabla 2 muestra los resultados de validación y test sobre la muestra para los tres modelos en comparación con el clasificador base (*Baseline* mayoritario).

Tabla 2: Métricas comparativas en el conjunto de prueba para el triage clínico

Modelo	Accuracy	Precision (Macro)	Recall (Macro)	F1 (Macro)	F1 (Weighted)
Baseline (Maj.)	52.20 %	13.05 %	25.00 %	17.16 %	35.83 %
Decision Tree	72.84 %	46.54 %	59.83 %	49.33 %	75.39 %
Random Forest	80.35 %	52.37 %	57.06 %	53.60 %	81.25 %
XGBoost	75.60 %	46.81 %	65.10 %	50.11 %	77.85 %



(a) Matriz de Confusión - Random Forest

(b) Matriz de Confusión - XGBoost

Figura 4: Matrices de confusión de los mejores clasificadores entrenados

El modelo **Random Forest** obtuvo el mejor desempeño global de **F1 Macro (53.60 %)** y exactitud (80.35 %), mostrando un excelente control sobre falsos positivos globales. No obstante, **XGBoost** alcanzó la tasa de recuperación más alta (**Recall Macro = 65.10 %**), demostrando una capacidad superior para capturar a los pacientes que terminarán en estado Crítico (Nivel 2) o Fallecido (Nivel 3). En el ámbito clínico, esta característica es prioritaria ya que minimiza los errores por omisión de pacientes vulnerables.

5.4 Curvas ROC y Feature Importance




Figura 5: Curvas ROC One-vs-Rest en conjunto de prueba para el clasificador óptimo

El análisis de área bajo la curva (AUC) presentado en la Figura 5 demuestra un excelente poder discriminativo, particularmente en el extremo severo (Fallecido AUC = 0.88 y Crítico AUC = 0.81). Las variables de mayor relevancia en la predicción del Random Forest (Figura 6) son consistentes con la experiencia médica clínica: **Neumonía** e **Edad** dominan fuertemente la ganancia de información del modelo, seguidas por **Diabetes**, **Hipertensión** y variables territoriales.




Figura 6: Clasificación de importancia de variables para la estimación de la severidad

5.5 Interpretación del Árbol de Decisión como Protocolo Clínico

El clasificador de árbol de decisión (**Decision Tree**) permite extraer un protocolo heurístico de fácil interpretación visual para personal de salud en campo:

- **Criterio Raíz (Neumonía):** Si el paciente no muestra neumonía en el triage inicial ($NEUMONIA \leq 0,5$), el algoritmo lo desvía por defecto a una baja severidad (Leve, Clase 0), a menos que co-existan factores de edad muy avanzados.
- **Criterio Secundario (Edad):** Si presenta neumonía ($NEUMONIA > 0,5$), el siguiente filtro crítico es la edad. Pacientes con edad mayor a un umbral de riesgo (aproximadamente $EDAD > 60$ años, o $EDAD_SCALED > 0,9$) se derivan directamente a hospitalización prioritaria (Clase 1) o terapia intensiva (Clase 2).
- **Criterios de Comorbilidad:** Para pacientes menores a 60 años con neumonía, el árbol evalúa la coexistencia de Diabetes, Hipertensión e Inmunosupresión para dictar si su manejo clínico debe ser hospitalario o ambulatorio de soporte.

6 Clustering (Agrupamiento)

El análisis no supervisado se orientó a segmentar a los pacientes según sus perfiles sociodemográficos y de comorbilidad para evaluar si existen agrupaciones intrínsecas correlacionadas con el nivel de gravedad real.

6.1 Metodología y Selección del Número de Clusters

Se seleccionaron 13 variables de comorbilidades y demografía general, escaladas previamente. Se evaluaron dos algoritmos: **K-Means** (como método principal) y **Clustering Jerárquico** (con enlace de Ward sobre una muestra estratificada de 5,000 registros para viabilidad computacional).

- **K-Means:** Se graficó la inercia (método del codo) y se calculó el coeficiente de silueta para valores de k entre 2 y 10 (Figura 7). El codo y el coeficiente de silueta indicaron de manera consistente un número óptimo de $k = 4$ **clusters** para segmentar la población.
- **Dendrograma Jerárquico:** El dendrograma obtenido sobre la muestra (Figura 8) evidenció que la distancia de enlace de Ward presenta un salto natural en 4 particiones, validando la consistencia estructural encontrada por K-Means.




Figura 7: Evaluación de número óptimo de clusters para K-Means




Figura 8: Dendrograma del agrupamiento jerárquico (Muestra de 5,000 casos)

6.2 Visualización y Perfilado de los Clusters

El heatmap de perfiles medios (Figura 9) representa la media de cada variable de riesgo en escala original dentro de cada cluster, lo que permite etiquetarlos clínicamente como se describe a continuación:




Figura 9: Heatmap de perfiles medios por variable clínica para los 4 clusters de K-Means

Tabla 3: Resumen y perfiles promedio de los 4 clusters de K-Means

Cluster	Casos (<i>n</i>)	%	Nombre Clínico	Características Clave	Severidad Media
0	96,080	43.2 %	Mujeres jóvenes sanas	Edad media 29.9 años, 100 % mujeres, sin comorbilidades relevante.	0.41
1	42,005	18.9 %	Adultos con síndrome metabólico	Edad media 66.9 años, mixto, alta prevalencia de Hipertensión (79 %) y Diabetes (55 %).	0.94
2	81,501	36.6 %	Hombres jóvenes sanos	Edad media 25.1 años, 100 % hombres, sin comorbilidades.	0.57
3	2,793	1.3 %	Mujeres embarazadas	Edad media 27.5 años, 100 % embarazadas, baja tasa de comorbilidad.	0.50

6.3 Validación de Clusters contra la Severidad Real

El análisis cruzado no supervisado indica que las variables demográficas basales y las comorbilidades capturan significativamente la gravedad final de la infección:

- La severidad media del **Cluster 1 (Adultos con síndrome metabólico)** es de **0.94**, siendo el doble o triple de los grupos sanos jóvenes.
- Los **Clusters 0 y 2** representan el 79.8 % de la población total de pacientes, caracterizando al grupo mayoritario de bajo riesgo asistencial, cuya severidad media fluctúa entre 0.41 y 0.57.
- El Coeficiente de Silueta global es de **0.2659** y el Índice de Rand Ajustado (ARI) frente a severidad real es de **0.0487** (Tabla 4). Esto es normal debido al solapamiento en el espacio de variables binarias dispersas, pero el modelo logra discriminar de forma robusta la severidad acumulando los casos más críticos y decesos en el Cluster 1 (Figura 10).

Tabla 4: Comparación métrica de calidad entre K-Means y Agrupamiento Jerárquico

Algoritmo	Muestra (n)	Coeeficiente Silueta	Rand Index Ajustado (ARI)
K-Means	222,379 (Total)	0.2659	0.0487
Jerárquico (Ward)	5,000 (Muestra)	0.4503	0.0124




Figura 10: Tabla de contingencia que muestra el porcentaje de severidad real por cluster

7 Arquitectura y Diseño del Sistema

7.1 Justificación de la Arquitectura y Patrones de Diseño

Para asegurar que la implementación del modelo de minería de datos sea robusta, extensible y fácil de integrar en un sistema de producción hospitalario, el código se estructuró siguiendo los principios de la programación orientada a objetos (POO) y utilizando patrones de diseño de software reconocidos:

1. **Patrón Factory Method (ModelFactory):** La clase `ModelFactory` centraliza y encapsula la instanciación de los clasificadores (`Decision Tree`, `Random Forest`, `XGBoost`).
 - *Justificación:* Evita acoplar el código cliente con clases específicas de bibliotecas de terceros (`scikit-learn` y `xgboost`). Si en el futuro se decide evaluar un clasificador basado en Redes Neuronales o SVM, solo se debe registrar en la factoría sin necesidad de modificar el pipeline principal de entrenamiento o evaluación.
2. **Patrón Pipeline (Modularización del Triage):** El flujo de trabajo se dividió en componentes desacoplados con responsabilidades únicas y bien definidas:
 - `DataLoader` y `DataPreprocessor`: Manejan la carga física, el formateo y la limpieza de datos limpios.
 - `ModelTrainer`: Contiene la lógica matemática de ajuste de hiperparámetros (`RandomizedSearchCV`), validación cruzada estratificada y manejo de pesos de clase.
 - `ModelEvaluator`: Especializado en la obtención de métricas de rendimiento y la genera-

ción de gráficos vectoriales sin alterar el estado del modelo.

7.2 Diagrama de Clases UML

El diagrama de la Figura 11 describe de forma exhaustiva las 7 clases principales que componen el sistema dentro de los módulos de la aplicación (`data/`, `models/` y `utils/`), detallando sus campos, métodos públicos y privados, así como las dependencias de flujo existentes.

Las clases mapeadas corresponden a:

- **DataLoader**: Responsable de leer de disco el CSV crudo, administrar la codificación de caracteres y detectar registros duplicados a nivel de identificadores únicos.
- **DataPreprocessor**: Encapsula el pipeline secuencial de transformación, la recodificación binaria, la estandarización de variables continuas (**StandardScaler**), la derivación de la variable ordinal **SEVERIDAD** y la separación estratificada en particiones.
- **AssociationRuleMiner**: Especializada en la minería de reglas de asociación usando los algoritmos Apriori y FP-Growth sobre las variables binarias de comorbilidad de la DGE.
- **ModelFactory**: Factoría encargada de instanciar de forma abstracta e intercambiable los clasificadores supervisados.
- **ModelTrainer**: Orquesta la ejecución del entrenamiento, el cálculo de pesos para desbalances y la sintonización fina de hiperparámetros.
- **ModelEvaluator**: Extrae métricas, genera matrices de confusión y traza las curvas ROC multi-clase.
- **ClusterAnalyzer**: Módulo no supervisado encargado de ejecutar agrupamiento con K-Means y jerárquico, analizar el codo/silueta, reducir dimensionalidad (PCA) y graficar perfiles medios.




Figura 11: Diagrama de Clases UML detallado de la arquitectura del sistema

7.3 Arquitectura del Sistema y Flujo de Datos

Para clarificar la secuencia operativa que experimentan los registros médicos de la DGE desde su ingesta hasta la inferencia y el agrupamiento, se diseñó un diagrama de flujo y arquitectura física (Figura 12).

La arquitectura se compone de tres capas principales bien delimitadas:

- **Capa de Ingesta y Preparación:** Encargada del consumo del archivo físico crudo (`COVID19MEXICO.csv`) a través del módulo `DataLoader` y su preprocesamiento en el pipeline del `DataPreprocessor`. Esto genera la base de datos limpia de 44 variables (`COVID19MEXICO_clean.csv`) que funciona como punto de entrada único para el resto del sistema.
- **Capa de Minería y Procesamiento de Datos:** Los datos limpios se distribuyen en tres ramas paralelas según el objetivo analítico: 1) La rama no supervisada (`ClusterAnalyzer`) para extraer perfiles medios. 2) La rama de asociación (`AssociationRuleMiner`) para buscar combinaciones frecuentes. 3) La rama supervisada que genera el split de datos (`X_train`, `y_train`, `X_test`, `y_test`).
- **Capa de Modelado e Inferencia Clínica:** El pipeline de machine learning supervisado consume el split de datos, instanciando los modelos a través de la factoría, ejecutando el entrenamiento y optimización en `ModelTrainer`, y arrojando reportes de métricas mediante

ModelEvaluator sin target leakage.




Figura 12: Diagrama de flujo operativo y arquitectura de datos del sistema

8 Reutilización del Modelo

8.1 Proceso de Serialización

Para garantizar la operatividad de los modelos entrenados en ambientes reales sin el costo computacional de re-entrenar con 222,000 registros en cada consulta, se implementó un flujo de persistencia. Utilizando la biblioteca `joblib`, los mejores estimadores encontrados tras la búsqueda de hiperparámetros se serializaron en archivos binarios independientes en el directorio `models/`. Por ejemplo, el modelo Random Forest óptimo se almacena como `models/random_forest_model.joblib`.

8.2 Demostración de Carga y Predicción en Frío (Notebook 05)

Para comprobar la portabilidad del modelo, se desarrolló el script interactivo `05_demo_modelo.ipynb`, el cual ejecuta las siguientes acciones:

1. **Carga del Modelo en Memoria:** Se recupera el clasificador serializado usando `joblib.load()` de manera instantánea.
2. **Ingreso de Datos de Triage:** Se simula el ingreso de un paciente en triage mediante un diccionario con variables sociodemográficas y antecedentes médicos basales (sin target leakage).
3. **Inferencia Instantánea:** El clasificador cargado predice la probabilidad del nivel de severidad

en milisegundos, retornando la clase y la justificación clínica asociada.

El fragmento de la sección listings (Código 1) ilustra la facilidad de reutilización del modelo clínico:

```
1 import joblib
2 import pandas as pd
3
4 # 1. Cargar el modelo guardado
5 model_path = "../models/random_forest_model.joblib"
6 modelo_cargado = joblib.load(model_path)
7
8 # 2. Datos de triage para un paciente ficticio (adulto mayor con
   comorbilidades)
9 nuevo_paciente = pd.DataFrame([
10     'EDAD_SCALED': 1.13, # Equivalente a ~65 años de edad
11     'SEXO': 1,           # Hombre
12     'DIABETES': 1,       # Tiene Diabetes
13     'HIPERTENSION': 1,   # Tiene Hipertension
14     'OBESIDAD': 0,       # No tiene Obesidad
15     'EPOC': 0,           # Sin EPOC
16     'ASMA': 0,           # Sin Asma
17     'INMUSUPR': 0,       # Sin Inmunosupresion
18     'RENAL_CRONICA': 1,  # Tiene enfermedad renal
19     'NEUMONIA': 1,       # Presenta Neumonía al ingreso
20     'TABAQUISMO': 0,
21     'OTRA_COM': 0,
22     'EMBARAZO': 0
23 ])
24
25 # 3. Realizar la prediccion clinica
26 prediccion = modelo_cargado.predict(nuevo_paciente)
27 probabilidades = modelo_cargado.predict_proba(nuevo_paciente)
28
29 print(f"Severidad Clinica Estimada: {prediccion[0]}")
30 print(f"Probabilidades por nivel (Leve, Grave, Critico, Fallecido): {
   probabilidades[0]}")
```

Listing 1: Fragmento de código demostrativo para predicción en frío

9 Conclusiones y Trabajo Futuro

9.1 Hallazgos Principales

- El análisis exploratorio y el modelado supervisado demuestran que las comorbilidades y el estado del paciente recopilados en el triage de ingreso contienen suficiente poder predictivo para estimar su severidad final.
- La **neumonía diagnóstica inicial** y la **edad avanzada** son los factores biológicos pre-

ponderantes en la severidad final de patologías respiratorias como COVID-19 e Influenza en México.

- Los modelos supervisados superan drásticamente al baseline trivial. **Random Forest** se destaca en exactitud global (80.35 %), pero el modelo **XGBoost** es el candidato óptimo para uso hospitalario real debido a su elevado Recall Macro (65.10 %), minimizando el riesgo de dar de alta a pacientes en peligro latente.
- La segmentación no supervisada (K-Means) de manera coherente agrupó a la población en perfiles clínicamente interpretables, revelando un grupo de alto riesgo metabólico que abarca adultos de edad avanzada con coexistencia de diabetes e hipertensión, el cual registra una severidad promedio de 0.94.

9.2 Limitaciones del Trabajo

La principal limitación radica en el origen retrospectivo del dataset centinela, el cual carece de variables dinámicas como signos vitales (saturación de oxígeno, frecuencia respiratoria) y datos de laboratorio de urgencia, los cuales mejorarían significativamente el poder discriminante en las clases intermedia e intubado.

9.3 Trabajo Futuro

- Integrar variables fisiológicas de tiempo real al pipeline.
- Explorar modelos de aprendizaje profundo (Deep Learning) capaces de procesar la progresión de las comorbilidades.
- Diseñar una interfaz gráfica web conectada a la factoría de modelos para facilitar la interacción de médicos de zonas rurales con la herramienta.

10 Referencias

1. Carranza-Salazar, D. E., Escobedo-de la Peña, J., & Lomas-López, M. (2020). Prevalencia de comorbilidades en pacientes con COVID-19 y su asociación con la mortalidad hospitalaria en México. *Salud Pública de México*, 62(6), 724-732. <https://doi.org/10.21149/11543>
2. Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794). ACM. <https://doi.org/10.1145/2939672.2939785>
3. Dirección General de Epidemiología. (2026). *Datos Abiertos del Sistema de Vigilancia Epidemiológica de Enfermedades Respiratorias Virales en México*. Secretaría de Salud, Gobierno de México. <https://www.gob.mx/salud/documentos/datos-abiertos-152127>
4. Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
5. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.